



中山大學
SUN YAT-SEN UNIVERSITY

本科生实验报告

外卖三方推荐与动态履约仿真系统

实验课程： 大数据原理与技术

专业名称： 计算机科学与技术

实验地点： 东校园实验中心大楼 B201

报告时间： 2026/7/6

组员	成员 1	成员 2	成员 3	成员 4
学号	23342035	23336011	23336003	23320143
姓名	黄镇邦	谭栋泽	陈政宇	唐雅妍

目录

1	符号定义	2
2	数据来源	3
3	推荐系统框架	4
3.1	基准模型	4
3.2	用户特征	4
3.3	三方重排	5
3.4	基于商品重排	6
3.4.1	会话点击信号	6
3.4.2	SPU 菜品画像信号	6
3.4.3	候选集扩展	7
3.4.4	分数组合与重排	7
3.5	知识图谱增强	7
4	履约仿真模块	8
4.1	仿真策略与 MNL 用户选择模型	8
4.2	骑手配送策略	9
4.3	二分图匹配派单	9
4.4	路径规划逻辑	9
4.5	地理编码逻辑	10
5	系统评估	10
5.1	推荐指标	10
5.2	履约指标与平台效用	11
5.3	离线推荐结果	11
5.4	实验数据分析	12
5.5	动态履约仿真结果	13
6	demo 演示	15
7	总结与局限	16
8	核心代码框架	16

1 符号定义

本文研究一个由推荐系统与履约仿真系统耦合形成的外卖平台闭环。推荐模块在给定用户与上下文后产生商家排序；用户选择模型将排序转化为模拟订单；履约模块再将订单分配给骑手并更新系统状态。为避免工程变量与数学变量混用，表 1 给出全文统一使用的符号。

表 1: 主要数学符号

符号	含义
$\mathcal{U}, \mathcal{M}, \mathcal{R}$	用户、商家、骑手集合
u, m, r	用户、商家、骑手的元素
t	离散时间步或推荐请求时间
$\mathcal{H}_u$	用户 u 的历史交互序列
$\mathcal{Y}_u$	用户 u 在评估集中的真实相关商家集合
$\mathcal{C}_u$	推荐阶段为用户 u 生成的候选商家集合
π_u^K	面向用户 u 的长度为 K 的推荐列表
$\text{rank}_{\pi_u}(m)$	商家 m 在列表 π_u 中的位置
c_m, a_m, p_m	商家 m 的品类、区域和价格段属性
q_m, n_m	商家 m 的质量估计与历史订单量
x_u, x_m, x_r	用户、商家和骑手的空间位置
$d(x, y)$	空间位置 x 与 y 间的配送距离估计
$\tau(u, m, t)$	用户 u 在时间 t 从商家 m 下单的预计履约时间
$s(u, m, t)$	推荐模型给出的预测偏好强度
$\phi_j(u, m, t), \theta_j$	第 j 类特征函数及其权重
$\tilde{x}$	变量 x 在候选集合内的归一化值
$b(m), e(u, m, t), h(m)$	商家公平、时效效用和供给可行性分量
$g(u, m, t)$	三方重排的综合价值函数
$\mathcal{E}, \mathcal{L}, \mathcal{G}$	知识图谱实体、关系和三元组集合
$\mathbf{z}_x$	实体或关系 x 的低维表示向量
$\mathcal{O}_t$	时间步 t 产生的订单集合
$\mathcal{B}_t$	时间步 t 的可用骑手容量槽集合
x_{ob}	订单 o 是否分配到容量槽 b 的二元决策变量
Q_r	骑手 r 当前待执行路径序列
$\Delta(r, o)$	将订单 o 插入骑手 r 路径后的最小边际绕行成本
$N_{um}, A_{um}(t)$	历史交互次数和距上次交互的时间间隔
L, γ, η	序列窗口、时间衰减尺度和位置衰减系数
$\alpha, \beta, \chi, \delta$	三方价值函数中各分量的权重
$\lambda_r, \lambda_d, \lambda_l$	列表重排中相关性、多样性和长尾奖励权重
$\ell(m)$	商家 m 的长尾奖励
$\mu, \omega_l, k(u, m, t)$	图谱时间衰减、关系权重和图谱相似度

表 1 (续): 主要数学符号

符号	含义
$\mathcal{P}_u, \mathcal{P}_m, \zeta(u, m)$	用户菜品偏好、商家菜品画像和菜品亲和度
$z(u, m, t), z_0$	下单选择效用和不下单效用
$\rho_r, L_r, \kappa(o, r)$	骑手可靠性、当前负载和接单可行性
$A(o, r), W_{ob}$	单订单派单价值和二分图边权
$J(r, o), \omega$	路径派单目标和绕行权衡系数
v_r, ς, τ_0	骑手速度、道路弯曲系数和超时阈值
Ψ	平台综合效用
$\mathbb{I}[\cdot]$	指示函数, 条件成立取 1, 否则取 0

2 数据来源

实验主要使用 Takeout Recommendation Dataset (TRD), 其 DOI 为 10.5281/zenodo.8025855[1]。该数据集来自外卖平台在北京 11 个商圈的真实订单记录, 时间跨度为 2021 年 3 月 1 日至 3 月 28 日, 包含用户、商家、菜品、训练期订单、测试期订单与测试标签。TRD 在本文中承担两类作用: 其一, 作为推荐系统的交互样本, 用于估计用户偏好、商家流行度和品类偏好; 其二, 作为订单生成的经验分布, 使履约仿真中的用户请求保持外卖场景的复购性、区域性和品类偏好。

表 2: TRD 数据统计

统计项	数值
训练订单数	1,068,495
用户数	200,000
商家数	29,072
测试订单数	230,550
离线评估用户数	300

TRD 不包含真实骑手轨迹与派单记录, 因此履约侧的骑手集合 $\mathcal{R}$ 由固定随机种子生成, 并可由公开末端配送任务数据校准速度、服务时长和负载分布。TRD 也不提供精确经纬度, 地理模块将用户与商家映射到真实城市配送点的空间分布中, 使距离函数 $d(\cdot, \cdot)$ 与预计履约时间 $\tau(\cdot)$ 具有合理的城市尺度。该设定用于比较不同推荐与派单策略的相对效能, 而不声称恢复平台真实派单过程。

3 推荐系统框架

3.1 基准模型

热门推荐将商家历史订单量 n_m 作为排序依据:

$$s_{\text{pop}}(u, m, t) = n_m. \quad (1)$$

该模型不依赖用户个性化信息, 用于衡量全局流行度偏置的下界表现。

贝叶斯个性化排序矩阵分解(BPR-MF)[2] 为每个用户和商家学习潜在表示 $\mathbf{z}_u, \mathbf{z}_m \in \mathbb{R}^d$, 预测偏好强度为

$$s_{\text{mf}}(u, m, t) = \mathbf{z}_u^\top \mathbf{z}_m. \quad (2)$$

对于训练样本三元组 (u, i, j) , 其中 i 是用户 u 交互过的商家、 j 是未交互商家, 优化目标为

$$\max_{\Theta} \sum_{(u, i, j)} \log \sigma(s_{\text{mf}}(u, i, t) - s_{\text{mf}}(u, j, t)) - \lambda \|\Theta\|_2^2. \quad (3)$$

该目标直接优化成对排序关系, 是隐式反馈推荐中的经典基准。

用户特征基准将品类偏好、复购、价格匹配、时段偏好、商家质量和新颖性写为统一特征函数 $\phi_j(u, m, t)$, 这些特征均归一化到 $[0, 1]$ 区间以保证数值稳定性, 并采用线性偏好函数:

$$s_{\text{prof}}(u, m, t) = \sum_{j=1}^J \theta_j \phi_j(u, m, t), \quad \sum_{j=1}^J \theta_j = 1, \quad \theta_j \geq 0. \quad (4)$$

其中, 复购特征定义为

$$\phi_{\text{rep}}(u, m, t) = \frac{\log(1 + N_{um})}{\log(\max_{u, m} N_{um} + 1)}, \quad (5)$$

其中 N_{um} 表示用户 u 在训练期对商家 m 的历史交互次数。

3.2 用户特征

序列推荐假设用户近期行为对下一次选择具有更强解释力。设 $A_{um}(t)$ 为用户 u 上一次交互商家 m 距离时间 t 的间隔, 则近期性特征可写为

$$\phi_{\text{rec}}(u, m, t) = \exp\{-A_{um}(t)/\gamma\}, \quad (6)$$

其中 γ 控制时间衰减速度。商家转移特征用条件转移概率表示：

$$\phi_{\text{tr}}(u, m, t) = \max_{k \leq L} \eta^k P(m \mid m_{t-k}), \quad (7)$$

其中 m_{t-k} 为用户历史序列中第 k 个近邻商家， L 为回看窗口， $\eta \in (0, 1)$ 为位置衰减系数。

规则型序列模型 (Seq-Tuned) 采用固定权重得到

$$s_{\text{seq}}(u, m, t) = \sum_j \theta_j \phi_j(u, m, t). \quad (8)$$

学习排序模型 (Logistic-LTR) 使用 Scikit-learn[6] 提供的 `LogisticRegression` 模块，来对权重进行自适应调整。实验中，学习排序主要用于检验手工特征权重能否由数据驱动的非线性函数替代。

3.3 三方重排

外卖推荐的目标不应只最大化预测偏好。若推荐列表持续把订单导向距离远、供给紧张或已高度曝光的商家，平台侧履约质量和生态公平会下降。因此本文将候选商家 $m \in \mathcal{C}_u$ 的价值分解为用户偏好、商家公平、时效和供给四个分量。

商家公平分量惩罚过度曝光的头部商家，并奖励具有较高质量的长尾商家：

$$b(m) = 0.75(1 - \tilde{n}_m) + 0.25\tilde{q}_m. \quad (9)$$

时效分量将预计履约时间转化为效用：

$$e(u, m, t) = 1 - \min\{\tau(u, m, t)/\tau_{\max}, 1\}. \quad (10)$$

供给分量综合商家配送能力与长尾供给：

$$h(m) = 0.6\tilde{q}_m + 0.4 \frac{1}{1 + \log(1 + n_m)}. \quad (11)$$

三方综合价值函数为

$$g(u, m, t) = \alpha \tilde{s}(u, m, t) + \beta \tilde{b}(m) + \chi \tilde{e}(u, m, t) + \delta \tilde{h}(m), \quad (12)$$

其中 $\alpha + \beta + \chi + \delta = 1$ 。所有带波浪线的量均在当前候选集合 $\mathcal{C}_u$ 内归一化，避免不同量纲导致权重不可解释。

列表级重排 (Seq-xQuAD-Tripartite) 借鉴多样化检索中的逐步选择思想 [7]。设 S

为已选择商家集合，则下一项由

$$m^* = \arg \max_{m \in \mathcal{C}_u \setminus S} [\lambda_r \tilde{g}(u, m, t) + \lambda_d \mathbb{I}[c_m \notin C(S)] + \lambda_l \ell(m)] \quad (13)$$

给出，其中 $C(S)$ 是已选商家的品类集合， $\ell(m) = 1/(1 + \log(1 + n_m))$ 是长尾奖励。该策略使推荐列表同时考虑相关性、多样性和商家侧曝光分布。

3.4 基于商品重排

在三方重排框架基础上，融合了真实行为信号与 SPU 菜品画像，增强了召回阶段的个性化表征能力。模型 (Session-SPU-Tripartite) 仅使用训练期订单数据进行拟合，以避免评估阶段的信息泄露。

3.4.1 会话点击信号

预处理阶段构建用户 u 的训练期点击序列 $S_u = [m_1, m_2, \dots, m_n]$ ，其中序列已根据请求时间倒序与点击 **rank** 正序进行了排序。会话分数 $session(u, m)$ 基于点击位置的指数衰减定义如下：

$$session(u, m) = \begin{cases} \exp\left(-\frac{\text{rank}_{\pi_u}(m)-1}{4}\right), & m \in S_u \\ 0, & m \notin S_u \end{cases} \quad (14)$$

该函数赋予近期高频点击商家更高的偏好权重。

3.4.2 SPU 菜品画像信号

模型通过统计用户与商家的菜品类目分布计算 SPU 亲和度 $\zeta(u, m)$ 。设 $n_{u,c}$ 和 $n_{m,c}$ 分别为用户 u 与商家 m 在类目 c 下的累计订单计数，则亲和度定义为：

$$\zeta(u, m) = \min\left(\frac{\sum_{c \in \mathcal{P}_u \cap \mathcal{P}_m} \min(n_{u,c}, n_{m,c})}{\max(\sum_c n_{u,c}, 1)}, 1\right) \quad (15)$$

此指标衡量了候选商家提供的菜品类目对用户 u 历史偏好集 $\mathcal{P}_u$ 的覆盖程度。

3.4.3 候选集扩展

Session-SPU-Tripartite 扩展后的召回候选集 $\mathcal{C}_{ssp}(u)$ 由多源召回拼接而成:

$$\mathcal{C}_{session}(u) = \{m : m \in S_u, m \in \text{active_set}\} \quad (16)$$

$$\mathcal{C}_{spu}(u) = \{m : m \in \text{active_set}, \mathcal{P}_m \cap \text{Top3}(\mathcal{P}_u) \neq \emptyset\} \quad (17)$$

$$\mathcal{C}_{ssp}(u) = \text{dedup}(\mathcal{C}_{session}(u) \oplus \text{Top120}(\mathcal{C}_{spu}(u)) \oplus \mathcal{C}_{seq}(u)) \quad (18)$$

其中 $\mathcal{C}_{seq}(u)$ 为原始序列召回候选, 通过该策略, 模型有效捕捉了“用户主动点击”与“菜品类目重合”两类核心信号。

3.4.4 分数组合与重排

模型增强后的原始得分 $score_{raw}^{ssp}(u, m)$ 综合了三方权重及新接入的会话与 SPU 信号:

$$score_{raw}^{ssp}(u, m) = g(u, m, t) + 0.055 \cdot session(u, m) + 0.015 \cdot \zeta(u, m) \quad (19)$$

其中 $g(u, m, t)$ 为预定义的加权三方价值函数 (权重分别为 0.86, 0.025, 0.03, 0.015)。在排序阶段, 系统沿用 xQuAD 列表重排机制, 通过下式贪婪选择最终推荐列表 π_u^K 中的商家 m^* :

$$m^* = \arg \max_{m \notin \pi_u} [0.84 \cdot \widetilde{score}_{raw}^{ssp}(m) + 0.12 \cdot \mathbb{I}[cat_m \notin C_{\pi_u}] + 0.04 \cdot \ell(m)] \quad (20)$$

该逻辑在确保三方公平性与供给可行性的同时, 通过引入 session 与 SPU 信号显著提升了推荐结果的相关性。

3.5 知识图谱增强

知识图谱用于建模用户、商家、品类、区域、价格段、口味和菜品实体之间的语义关系; 相关图推荐方法可参考 KGAT 与 LightGCN[9, 10]。定义图谱三元组集合

$$\mathcal{G} \subseteq \mathcal{E} \times \mathcal{L} \times \mathcal{E}, \quad (21)$$

其中 $\mathcal{E}$ 为实体集合, $\mathcal{L}$ 为关系集合。每个实体或关系被映射为低维表示 $\mathbf{z}_x$ 。用户在时间 t 的图谱兴趣由历史交互的时间衰减聚合给出:

$$\mathbf{z}_{u,t}^{\text{kg}} = \sum_{(m_i, t_i) \in \mathcal{H}_u} \exp\{-\mu(t - t_i)\} \sum_{(m_i, l, e) \in \mathcal{G}} \omega_l \mathbf{z}_e, \quad (22)$$

其中 μ 为时间衰减系数, ω_l 表示关系 l 的重要性。候选商家的图谱表示为

$$\mathbf{z}_m^{\text{kg}} = \sum_{(m,l,e) \in \mathcal{G}} \omega_l \mathbf{z}_e. \quad (23)$$

图谱增强分量定义为

$$k(u, m, t) = \frac{\left(\mathbf{z}_{u,t}^{\text{kg}}\right)^\top \mathbf{z}_m^{\text{kg}}}{\|\mathbf{z}_{u,t}^{\text{kg}}\|_2 \|\mathbf{z}_m^{\text{kg}}\|_2}. \quad (24)$$

在三方推荐中, $k(u, m, t)$ 与用户偏好分量共同进入 $s(u, m, t)$ 或作为额外项进入 $g(u, m, t)$ 。其作用是将“用户近期消费过相同品类、相近价位、同一区域或相似菜品”的结构化证据引入排序, 同时保留可解释路径。

SPU 菜品信号可视为图谱的一类细粒度实体。设 $\mathcal{P}_u$ 为用户历史消费菜品类别的多重集合, $\mathcal{P}_m$ 为商家售卖菜品类别的多重集合, 则菜品亲和度定义为

$$\zeta(u, m) = \min \left\{ \frac{\sum_{c \in \mathcal{P}_u \cap \mathcal{P}_m} \min(N_{u,c}, N_{m,c})}{\max(1, \sum_c N_{u,c})}, 1 \right\}. \quad (25)$$

该分量为会话点击和菜品偏好的联合建模提供了比商家级交互更细的解释粒度。

4 履约仿真模块

4.1 仿真策略与 MNL 用户选择模型

推荐列表并不必然转化为订单。本文用多项逻辑模型刻画用户在推荐列表中的选择概率 [3, 4]。设商家 m 在推荐列表 π_u^K 中的位置为 $\text{rank}_{\pi_u}(m)$, 用户对该商家的选择效用为

$$z(u, m, t) = \lambda_0 + \lambda_s \tilde{s}(u, m, t) + \lambda_p \frac{1}{\log_2(1 + \text{rank}_{\pi_u}(m))} + \lambda_y \mathbb{I}[m \in \mathcal{Y}_u]. \quad (26)$$

不下单选项的效用记为 z_0 。则用户从推荐列表中选择商家 m 的概率为

$$P(m \mid u, \pi_u^K, t) = \frac{\exp(z(u, m, t))}{\exp(z_0) + \sum_{j \in \pi_u^K} \exp(z(u, j, t))}. \quad (27)$$

该模型使推荐排序通过选择概率影响订单空间分布, 从而将推荐系统与后续履约过程耦合。

4.2 骑手配送策略

对于订单 $o = (u, m, t)$, 最近距离策略选择取餐距离最短的骑手:

$$r^* = \arg \min_{r \in \mathcal{R}_t} d(x_r, x_m), \quad (28)$$

其中 x_r 与 x_m 分别表示骑手和商家的位置。最小预计履约时间策略选择

$$r^* = \arg \min_{r \in \mathcal{R}_t} \tau(o, r). \quad (29)$$

负载感知策略将履约时间、骑手可靠性和当前负载合并为可派单价值:

$$A(o, r) = \xi_1 (1 - \min\{\tau(o, r)/\tau_{\max}, 1\}) + \xi_2 \rho_r + \xi_3 \frac{1}{1 + L_r} + \xi_4 \kappa(o, r), \quad (30)$$

其中 ρ_r 为骑手可靠性, L_r 为当前负载, $\kappa(o, r)$ 为接单可行性估计。逐单贪心策略选择 $A(o, r)$ 最大的骑手。

4.3 二分图匹配派单

逐单贪心可能产生局部最优。批量派单在时间步 t 将订单集合 $\mathcal{O}_t$ 与可用容量槽集合 $\mathcal{B}_t$ 构成二分图。设容量槽 b 对应骑手 $r(b)$, 边权为

$$W_{ob} = A(o, r(b)) - \psi \max\{\tau(o, r(b)) - \tau_0, 0\}, \quad (31)$$

其中第二项惩罚高超时风险。全局匹配问题为

$$\max_x \sum_{o \in \mathcal{O}_t} \sum_{b \in \mathcal{B}_t} W_{ob} x_{ob} \quad (32)$$

$$\text{s.t.} \quad \sum_{b \in \mathcal{B}_t} x_{ob} \leq 1, \quad \sum_{o \in \mathcal{O}_t} x_{ob} \leq 1, \quad x_{ob} \in \{0, 1\}. \quad (33)$$

该问题是标准最大权二分图匹配, 可用匈牙利算法求解 [8]。与贪心策略相比, 它在同一批订单和骑手容量上优化全局目标。

4.4 路径规划逻辑

当骑手已经携带或等待多个订单时, 单点预计履约时间不足以描述顺路接单价值。设 $L(Q_r)$ 为骑手 r 当前路径序列 Q_r 的总行驶成本。将订单 o 的取餐点和送达点插入

路径后的最小边际绕行为

$$\Delta(r, o) = \min_{i < j} [L(Q_r \oplus_{i,j} o) - L(Q_r)], \quad (34)$$

其中 $\oplus_{i,j}$ 表示将取餐点插入第 i 个位置、送达点插入第 j 个位置且满足先取后送的可行路径操作。路径感知派单可最小化

$$J(r, o) = \omega \Delta(r, o) + (1 - \omega) \tau(o, r), \quad (35)$$

其中 ω 控制绕行成本与订单时效之间的权衡。运力紧张时, 该策略能够利用骑手现有路径吸收顺路订单。

4.5 地理编码逻辑

地理编码将用户和商家映射到二维空间点 $x_u, x_m \in \mathbb{R}^2$ 。若真实坐标不可得, 可将区域 a 表示为混合分布

$$x \mid a \sim \sum_{h=1}^H \nu_{a,h} \mathcal{N}(\mu_{a,h}, \Sigma_{a,h}), \quad (36)$$

其中 $\mu_{a,h}$ 和 $\Sigma_{a,h}$ 由真实城市配送点云估计。距离采用道路弯曲修正:

$$d(x, y) = \varsigma \|x - y\|_2, \quad \varsigma > 1. \quad (37)$$

预计履约时间由备餐、取餐行驶、送达行驶、高峰修正与负载修正组成:

$$\tau(o, r) = T_{\text{prep}}(m) + \frac{d(x_r, x_m)}{v_r} + \frac{d(x_m, x_u)}{v_r} + T_{\text{peak}}(t) + T_{\text{load}}(r). \quad (38)$$

5 系统评估

5.1 推荐指标

给定用户 u 的真实相关集合 $\mathcal{Y}_u$ 与推荐列表 π_u^K , 召回率定义为

$$\text{Recall@K} = \frac{1}{|\mathcal{U}_{\text{eval}}|} \sum_{u \in \mathcal{U}_{\text{eval}}} \frac{|\pi_u^K \cap \mathcal{Y}_u|}{|\mathcal{Y}_u|}. \quad (39)$$

折损累计增益定义为

$$\text{DCG@K}(u) = \sum_{j=1}^K \frac{\mathbb{I}[\pi_u(j) \in \mathcal{Y}_u]}{\log_2(j+1)}, \quad (40)$$

归一化折损累计增益为 [5]

$$\text{NDCG@K} = \frac{1}{|\mathcal{U}_{\text{eval}}|} \sum_{u \in \mathcal{U}_{\text{eval}}} \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}. \quad (41)$$

平均倒数排名为

$$\text{MRR@K} = \frac{1}{|\mathcal{U}_{\text{eval}}|} \sum_{u \in \mathcal{U}_{\text{eval}}} \frac{1}{\min\{j : \pi_u(j) \in \mathcal{Y}_u\}}, \quad (42)$$

若前 K 位无命中, 则该用户贡献为 0。

商家覆盖率衡量至少被推荐一次的商家占比:

$$\text{Coverage@K} = \frac{|\cup_u \pi_u^K|}{|\mathcal{M}|}. \quad (43)$$

曝光公平性用 Gini 系数衡量。设 E_m 为商家 m 的曝光次数, 并按升序排列为 $E_{(1)} \leq \dots \leq E_{(M)}$, 则

$$\text{Gini} = \frac{\sum_{i=1}^M (2i - M - 1) E_{(i)}}{M \sum_{i=1}^M E_{(i)}}. \quad (44)$$

5.2 履约指标与平台效用

履约指标包括平均预计履约时间、超时率、准时率、完成率、骑手负载离散度与骑手收入公平性。平均预计履约时间为

$$\bar{\tau} = \frac{1}{|\mathcal{O}|} \sum_{o \in \mathcal{O}} \tau(o), \quad (45)$$

超时率定义为

$$r_{\text{late}} = \frac{1}{|\mathcal{O}|} \sum_{o \in \mathcal{O}} \mathbb{I}[\tau(o) > \tau_0]. \quad (46)$$

平台效用函数综合用户、商家与骑手三方目标:

$$\Psi = 0.25S_u + 0.25R_{\text{on}} + 0.20R_{\text{comp}} + 0.15(1 - G_m) + 0.10(1 - C_r) - 0.05R_{\text{late}}, \quad (47)$$

其中 S_u 为平均用户满意度, R_{on} 为准时率, R_{comp} 为完成率, G_m 为商家曝光 Gini, C_r 为骑手负载变异系数, R_{late} 为超时率。

5.3 离线推荐结果

表 3 给出主要模型在 $K = 20$ 下的推荐准确性。Seq-Tuned 在召回率上最高, 说明外卖推荐强烈受复购和序列转移驱动; KG-Tripartite 在三方模型中取得最高的 NDCG,

说明图谱语义信号能够改善排序位置质量。

表 3: 离线推荐准确性指标 ($K = 20$)

模型	Recall@20	NDCG@20
Popular	0.0470	0.0210
BPR-MF	0.1620	0.1068
UserOnly	0.4287	0.3423
Logistic-LTR	0.4013	0.3412
Seq-Tuned	0.4675	0.3652
Seq-xQuAD-Tripartite	0.4113	0.3426
Session-SPU-Tripartite	0.4119	0.3429
KG-Tripartite	0.4263	0.3480

表 4: 离线推荐覆盖与公平性指标 ($K = 20$)

模型	Coverage@20	Exposure Gini	Category JSD
Popular	0.0062	0.9952	0.0581
BPR-MF	0.1350	0.9516	0.0575
UserOnly	0.2841	0.8857	0.0156
Logistic-LTR	0.4290	0.8282	0.4736
Seq-Tuned	0.2884	0.8927	0.0152
Seq-xQuAD-Tripartite	0.2823	0.8904	0.0154
Session-SPU-Tripartite	0.2884	0.8818	0.0158
KG-Tripartite	0.2927	0.8746	0.0157

5.4 实验数据分析

离线推荐结果显示，实验数据具有明显的复购和序列依赖特征。Popular 的 Recall@20 仅为 0.0470，说明全局热度无法刻画用户个体偏好；BPR-MF 将 Recall@20 提升到 0.1620，但仍明显低于显式用户画像和序列特征模型。Seq-Tuned 的 Recall@20 达到 0.4675，较 UserOnly 提高 9.05%，较 BPR-MF 提高 188.58%，说明用户近期消费、复购、品类偏好和商家转移关系是 TRD 外卖场景中最有效的预测信号。

从排序质量看，Seq-Tuned 的 NDCG@20 为 0.3652，是所有模型中最高的，说明命中项不仅进入了前 20，也更靠近列表前部。KG-Tripartite 的 Recall@20 为 0.4263、NDCG@20 为 0.3480，在三方模型中最优，表明品类、区域、价位和菜品等图谱语义可以在引入公平与履约约束后部分弥补精度损失。Session-SPU-Tripartite 与 Seq-xQuAD-Tripartite 的准确率接近，但前者在仿真中获得更高平台效用，说明菜品细粒度信号对后续订单选择与履约链路更有帮助。

公平性指标揭示了另一类重要现象：高准确率并不自然带来合理曝光。Popular 的 Coverage@20 只有 0.0062，Exposure Gini 高达 0.9952，说明热门推荐几乎把曝光集中

在极少数头部商家。Logistic-LTR 将 Coverage@20 提升到 0.4290，并把 Exposure Gini 降到 0.8282，但 Category JSD 升高到 0.4736，说明覆盖扩张伴随明显的品类分布偏移。相比之下，Seq-Tuned 与三方重排模型保持了约 0.015 的 Category JSD，能更好维持用户历史品类偏好；其中 KG-Tripartite 将 Exposure Gini 降至 0.8746，较 Seq-Tuned 下降 2.03%，体现出三方重排在准确率、曝光公平和用户习惯之间的折中能力。



图 1: 离线推荐准确性指标可视化




图 2: 离线推荐覆盖与曝光公平性可视化

5.5 动态履约仿真结果

常规运力场景使用 120 名骑手，表 5 报告 10 个随机种子的均值与 95% 置信区间。结果表明，离线准确率最高的策略并不必然带来最优履约表现；三方重排配合批量匹配在平均预计履约时间、超时率和平台效用上明显优于纯用户侧策略。

常规运力场景进一步说明，履约指标对推荐排序非常敏感。与热门推荐加最近距离相比，序列三方重排加批量匹配将平均预计履约时间从 59.06 分钟降至 35.90 分钟，下降 39.22%；超时率从 0.579 降至 0.195，下降 66.32%；平台效用从 0.391 提升到 0.553，提升 41.43%。会话-SPU 三方重排的平均 ETA 略高于序列三方重排，但平台效用最高，说明平台效用并非单一 ETA 指标，而是用户满意度、准时率、完成率、商家公平和骑手负载共同作用的结果。

在运力紧张场景中，骑手数量下降至 30 名。表 6 显示路径感知派单在高峰爆单时

表 5: 常规运力履约仿真结果 (120 名骑手, 均值 $\pm$ 95% 置信区间)

策略	平均预计履约时间	超时率	准时率	平台效用
热门推荐 + 最近距离	59.06 $\pm$ 2.28	0.579 $\pm$ 0.023	0.421 $\pm$ 0.023	0.391 $\pm$ 0.007
用户画像 + 最小时效	41.54 $\pm$ 1.23	0.347 $\pm$ 0.031	0.653 $\pm$ 0.031	0.511 $\pm$ 0.009
序列模型 + 最小时效	40.44 $\pm$ 1.21	0.287 $\pm$ 0.041	0.713 $\pm$ 0.041	0.533 $\pm$ 0.012
序列三方重排 + 批量匹配	35.90 $\pm$ 1.88	0.195 $\pm$ 0.036	0.805 $\pm$ 0.036	0.553 $\pm$ 0.009
会话-SPU 三方重排 + 批量匹配	36.79 $\pm$ 1.25	0.199 $\pm$ 0.029	0.801 $\pm$ 0.029	0.557 $\pm$ 0.010
KG 三方重排 + 批量匹配	36.90 $\pm$ 1.04	0.211 $\pm$ 0.033	0.789 $\pm$ 0.033	0.550 $\pm$ 0.011
KG 三方重排 + 路径最小时效	36.15 $\pm$ 0.96	0.229 $\pm$ 0.037	0.771 $\pm$ 0.037	0.542 $\pm$ 0.011

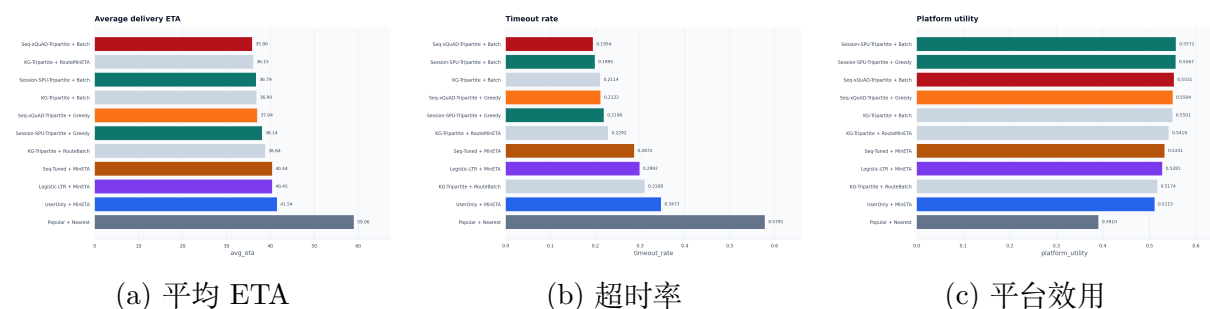


图 3: 常规运力下的履约仿真核心指标


具有明显优势。其原因是路径插入机制能利用骑手已有路线吸收边际绕行较小的订单，而容量槽匹配在稀缺运力下更容易产生远距离独立派单。

表 6: 运力紧张履约仿真结果 (30 名骑手, 均值 $\pm$ 95% 置信区间)


策略	平均预计履约时间	超时率	平台效用	顺路接单率
热门推荐 + 最近距离	76.86 $\pm$ 2.56	0.749 $\pm$ 0.029	0.412 $\pm$ 0.012	—
序列模型 + 最小时效	76.64 $\pm$ 2.46	0.819 $\pm$ 0.014	0.442 $\pm$ 0.014	—
序列三方重排 + 批量匹配	60.96 $\pm$ 4.84	0.679 $\pm$ 0.046	0.486 $\pm$ 0.017	—
KG 三方重排 + 批量匹配	61.47 $\pm$ 2.85	0.685 $\pm$ 0.039	0.481 $\pm$ 0.014	—
KG 三方重排 + 路径最小时效	44.88 $\pm$ 1.55	0.457 $\pm$ 0.038	0.544 $\pm$ 0.016	0.669 $\pm$ 0.016
KG 三方重排 + 路径批量匹配	47.34 $\pm$ 1.66	0.515 $\pm$ 0.040	0.525 $\pm$ 0.015	0.666 $\pm$ 0.015

运力紧张场景放大了派单策略差异。KG 三方重排加路径最小时效的平均 ETA 为 44.88 分钟, 较 KG 三方重排加批量匹配下降 26.99%, 超时率从 0.685 降至 0.457, 平台效用从 0.481 提升到 0.544。路径批量匹配虽然顺路接单率同样较高, 但平均 ETA 和超时率均弱于路径最小时效, 说明在强约束高峰期, 先压低单笔订单履约风险比追求批量全局匹配更关键。

综合推荐与履约两侧指标可以看到, Seq-Tuned 代表离线准确率前沿, 而 Session-SPU-Tripartite、KG-Tripartite 等三方策略代表系统效用前沿。图 4 展示了这一权衡关系: 越靠近右上方的策略, 越能同时保持较高 Recall@20 与较高平台效用; 而仅沿单一指标优化会导致曝光集中、ETA 上升或超时率恶化。



(a) 召回率与平台效用前沿



(b) 三方策略综合得分

图 4: 推荐准确率、履约表现与平台效用的综合权衡

6 demo 演示

本实验实现了一个可视化 demo，展示用户画像、推荐商家路径解释、骑手配送路径和不同配送策略下的路径对比。图 5 展示了 demo 的四个主要界面。



(a) 用户画像



(b) 推荐商家路径解释



(c) 骑手配送路径可视化



(d) 不同配送策略下的路径对比

图 5: demo 演示界面

7 总结与局限

本文将外卖推荐建模为“用户偏好排序—多目标重排—用户选择—骑手履约”的闭环问题。实验表明，单纯提高离线召回率并不等价于提升平台整体效用。Seq-Tuned 在离线召回上表现最强，但三方重排方法通过引入商家公平、时效和供给分量，显著降低平均预计履约时间和超时率。Session-SPU-Tripartite 在常规运力下取得最高平台效用，说明会话点击与菜品细粒度信号能够为三方闭环提供有价值的补充。KG-Tripartite 在三方模型中保持较高排序质量，并能通过品类、区域、价位和菜品路径提供可解释证据。

履约侧实验进一步显示，派单策略需要随供需状态变化。常规运力下，批量二分图匹配能在全局层面均衡骑手容量；运力紧张时，路径感知顺路派单通过最小化边际绕行成本显著降低预计履约时间和超时率。这一结果说明推荐系统与履约系统不应被视作两个独立模块，而应作为共同影响平台效用的联动系统进行评估。

本研究仍存在局限。首先，骑手轨迹与派单记录来自仿真生成，虽然可由公开配送任务数据校准，但不能完全替代工业级外卖平台数据。其次，MNL 用户选择模型是对真实下单行为的简化，尚未覆盖价格促销、店铺活动、天气和用户耐心等因素。再次，KG-Tripartite 当前主要采用轻量图谱兴趣匹配，尚未在完整闭环中训练端到端图神经网络。最后，三方重排与派单仍是解耦优化，未来可研究将推荐、选择和调度统一为端到端多目标决策问题。

8 核心代码框架

foodflow/	
cli.py	命令行入口
download.py	TRD 下载
preprocess.py	数据清洗与特征处理
data.py	处理后数据加载
recommenders.py	推荐基线、序列模型与三方重排
rerank.py	ETA、公平分、供给分等重排特征
kg.py	轻量知识图谱三元组与路径解释
rider_sim.py	骑手生成、ETA 估计、订单匹配
simulator.py	动态履约仿真
metrics.py	推荐与公平指标
evaluate.py	离线推荐评估
figures.py	图表生成
report.py	实验报告生成
explain.py	推荐解释

— app.py	Streamlit Demo
— Makefile.....	常用运行命令
— outputs/	指标 CSV 与图表
— report/	实验报告
— tests/	单元测试与集成 Smoke 测试

参考文献

- [1] Takeout Recommendation Dataset. 2023. Zenodo. DOI: 10.5281/zenodo.8025855.
- [2] Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. 2009. BPR: Bayesian Personalized Ranking from Implicit Feedback. *Proceedings of UAI*.
- [3] R. Duncan Luce. 1959. *Individual Choice Behavior: A Theoretical Analysis*. Wiley.
- [4] Daniel McFadden. 1974. Conditional Logit Analysis of Qualitative Choice Behavior. In *Frontiers in Econometrics*. Academic Press.
- [5] Kalervo Jarvelin and Jaana Kekalainen. 2002. Cumulated Gain-Based Evaluation of IR Techniques. *ACM Transactions on Information Systems*, 20(4):422–446.
- [6] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- [7] Rodrygo L. T. Santos, Craig Macdonald, and Iadh Ounis. 2010. Exploiting Query Reformulations for Web Search Result Diversification. *Proceedings of WWW*.
- [8] H. W. Kuhn. 1955. The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly*, 2(1–2):83–97.
- [9] Xiang Wang, Xiangnan He, Yixin Cao, Meng Liu, and Tat-Seng Chua. 2019. KGAT: Knowledge Graph Attention Network for Recommendation. *Proceedings of KDD*.
- [10] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. *Proceedings of SIGIR*.