



本科生实验报告

实验课程：大数据原理与技术

实验名称：外卖三方推荐与动态履约仿真系统

专业名称：计算机科学与技术

实验地点：东校园实验中心大楼 B201

报告时间：2026/7/6

组员	成员 1	成员 2	成员 3	成员 4
学号	23342035	23336011	23336003	23320143
姓名	黄镇邦	谭栋泽	陈政宇	唐雅妍

目录

1 项目定位：推荐系统与动态履约闭环	3
2 系统实现：推荐、三方重排与履约仿真	3
2.1 数据来源与预处理	3
2.2 推荐系统模块：序列、SPU 与 KG 增强	4
2.3 三方重排模块：用户、商家与履约约束	5
2.4 动态履约仿真模块	6
2.4.1 MNL 用户选择模型	7
2.4.2 骑手配送策略	7
2.5 二分图匹配派单算法	7
2.6 ETA 估计模型	8
2.7 平台效用函数	8
2.8 KG 增强与可解释推荐模块	8
2.8.1 知识图谱实体与关系设计	8
2.8.2 图谱兴趣构造：时间衰减与关系匹配	9
2.8.3 轻量 KG 路径解释	9
2.9 路径感知顺路派单	9
2.10 真实城市地理编码	10
3 系统评估：推荐效果与履约表现	10
3.1 FoodFlow 系统闭环实验	10
3.1.1 离线推荐结果	10
3.1.2 权衡分析：准确率 vs 公平性	12
3.1.3 动态履约仿真结果（常规运力 120 骑手）	12
3.1.4 运力紧张压力场景（30 骑手高峰爆单）	14
3.1.5 三方帕累托前沿分析	15
4 系统总结与局限	18

1 项目定位：推荐系统与动态履约闭环

本实验旨在构建一个面向外卖平台的推荐与动态履约仿真系统 FoodFlow。外卖推荐不能仅追求 Recall 或 NDCG——推荐列表会改变订单的空间分布，进而影响商家曝光、骑手负载、预计送达时间（ETA）和超时风险。因此 FoodFlow 在用户偏好之外，引入商家公平、ETA、供给约束和骑手负载，将推荐系统扩展为“用户—商家—骑手”三方闭环。

实验目标包括：

1. 基于真实外卖订单数据（TRD 数据集），实现多种推荐模型，包括协同过滤、序列推荐、学习排序（LTR）以及三方重排方法；
2. 构建动态履约仿真器，将推荐结果转化为模拟订单，接入骑手匹配与高峰期履约仿真；
3. 通过离线评估指标（Recall、NDCG、Coverage、Exposure Gini 等）和仿真指标（平均 ETA、超时率、平台效用等），综合评估不同策略在三方指标上的权衡。

2 系统实现：推荐、三方重排与履约仿真

2.1 数据来源与预处理

主数据集为 Takeout Recommendation Dataset (TRD), DOI:10.5281/zenodo.8025855。数据来自美团外卖北京 11 个商圈，时间范围为 2021-03-01 至 2021-03-28，包含用户、餐厅、菜品、训练订单、测试订单和测试标签。项目默认下载 TRD 的 txt 文件，训练集使用完整 `orders_train.txt`。

数据审计结果如表 1 所示。

TRD 不包含真实骑手数据，因此骑手位置、在线状态、负载和收入基于固定 seed 合成代理数据。可使用 LaDe delivery CSV 校准骑手速度、服务时长和负载分布，但 LaDe 并非外卖平台数据。

表 1: TRD 数据集审计结果

审计项目	数值
必需 TRD 文件齐全	是
训练集处理模式	full
原始训练订单数	1,068,495
处理后训练订单数	1,068,495
训练订单使用比例	1.0000
用户数	200,000
商家数	29,072
测试订单数	230,550
离线评估用户数	300 (前 300 名测试用户)

2.2 推荐系统模块：序列、SPU 与 KG 增强

系统实现了 8 个代表性推荐策略，涵盖从简单基线到知识图谱增强的不同层次：

Popular (全局热门基线)：按商家历史订单量排序，作为无个性化的对照组。

BPR-MF (贝叶斯个性化排序矩阵分解)：基于用户-商家隐式反馈，使用 24 维潜在因子、4 个 epoch 的 SGD 训练，是传统协同过滤的经典实现。

UserOnly (基于用户画像的可解释排序)：综合品类偏好 (权重 0.20)、复购 (0.52)、价格匹配 (0.10)、时段偏好 (0.06)、商家质量 (0.07) 和新颖度 (0.05)，构造完全可解释的推荐分数。

Seq-Tuned (序列混合推荐)：基于用户最近下单序列，提取快慢时间衰减、复购、商家转移、品类偏好、热度和质量等七类序列特征，通过人工调优的权重进行加权融合。权重配置为近因性 (0.143+0.094)、复购 (0.412)、转移 (0.247)、品类 (0.091)、热度 (0.009)、质量 (0.004)。

LightGBM-LTR (LambdaRank 学习排序)：复用 Seq-Tuned 的七类序列特征，使用 LightGBM LambdaRank 学习非线性排序函数，替代手工设定的权重。当 LightGBM 不可用时，自动回退为 Logistic-LTR。

推荐模型的候选集生成遵循以下流程：首先对每个用户提取历史下单序列和商家频次，计算七类序列特征值；然后基于特征分数对候选商家进行初筛，保留前 80 名进入重排阶段。核心特征计算公式如下：

对于复购特征 (repeat)，定义用户 u 对商家 m 的复购分为：

$$\text{repeat}(u, m) = \frac{\ln(1 + \text{count}(u, m))}{\ln 5} \quad (1)$$

其中 $\text{count}(u, m)$ 为用户 u 在训练集中下单商家 m 的总次数。

对于商家转移特征 (transition)，考虑用户序列中从商家 m_i 到 m_j 的转移概率：

$$\text{transition}(u, m) = \frac{\sum_{t=1}^{|\text{seq}|-1} \mathbb{I}[\text{seq}_t = m_{\text{prev}}] \cdot \text{COOCCUR}(m_{\text{prev}}, m)}{\max(1, |\text{seq}| - 1)} \quad (2)$$

Seq-xQuAD-Tripartite (序列推荐 + 三方重排)：在 Seq-Tuned 候选集基础上，引入三方重排架构。候选集经过 min-max 归一化后，加权合成四个分量：用户偏好分 (user_score, 权重 0.93)、商家公平分 (fairness, 权重 0.025)、ETA 分 (eta_score, 权重 0.03) 和供给分 (supply_score, 权重 0.015)。之后通过 xQuAD 算法进行逐步选择，平衡相关性 (权重 0.84)、品类覆盖多样性 (0.12) 和长尾曝光 (0.04)。

Session-SPU-Tripartite (会话与菜品增强三方)：在三方重排基础上，额外注入训练期会话点击候选和基于 SPU 菜品品类的商家亲和力。通过菜品品类重叠扩展候选集，session 权重为 0.055，spu 权重为 0.015。

KG-Tripartite(知识图谱增强三方推荐)：在三方重排架构之上，引入 foodflow/recommenders.py 中实现的轻量知识图谱兴趣信号。该模型不训练完整图神经网络，而是将 TRD 结构化字段 (商家类目、商圈区域、价格段、评分等级、口味、食材、品牌等) 组织为知识图谱三元组，通过时间衰减将用户历史订单转化为图谱上的带权兴趣边，在候选排序中叠加图谱路径匹配特征。KG-Tripartite 作为 FoodFlow 主推荐链路的一部分，通过时间衰减与关系加权匹配将图谱信号接入三方重排，并可从历史下单、品类、区域和价格段构造路径证据解释推荐原因。

2.3 三方重排模块：用户、商家与履约约束

三方重排是 FoodFlow 的核心创新点，其架构如图 1 所示。




图 1: FoodFlow 系统架构图

三方分数融合的具体计算方式如下：对于给定的候选商家集合 $\mathcal{C}$ ，首先对各分量的原始值进行 min-max 归一化，得到归一化分数 $\tilde{s}_u(m)$ （用户分）、 $\tilde{s}_f(m)$ （公平分）、 $\tilde{s}_e(m)$ （ETA 分）和 $\tilde{s}_s(m)$ （供给分）。三方总分由加权和给出：

$$s_{\text{tri}}(m) = w_u \cdot \tilde{s}_u(m) + w_f \cdot \tilde{s}_f(m) + w_e \cdot \tilde{s}_e(m) + w_s \cdot \tilde{s}_s(m) \quad (3)$$

其中权重满足 $w_u + w_f + w_e + w_s = 1$ 。

商家公平分的定义为 $s_f(m) = 0.75 \cdot (1 - \text{norm_pop}(m)) + 0.25 \cdot \text{quality}(m)$ ，即对高曝光商家进行惩罚、对高质量低曝光商家进行补偿。ETA 分定义为 $s_e(m) = 1.0 - \min(\text{eta}(m)/70.0, 1.0)$ 。供给分定义为 $s_s(m) = 0.6 \cdot (\text{delivery_score}(m)/5.0) + 0.4/(1 + \ln(1 + \text{order_count}(m)))$ ，综合考虑商家配送能力和长尾供给。

xQuAD 逐步选择的每一步中，对每个未被选中的候选商家 m ，计算其综合价值：

$$v(m) = \lambda_r \cdot \text{rel}(m) + \lambda_d \cdot \text{div}(m) + \lambda_t \cdot \text{tail}(m) \quad (4)$$

其中 $\text{rel}(m)$ 为归一化后的三方总分， $\text{div}(m) \in \{0, 1\}$ 表示该商家品类是否尚未被已选列表覆盖， $\text{tail}(m) = 1/(1 + \ln(1 + \text{order_count}(m)))$ 为长尾奖励。

2.4 动态履约仿真模块

仿真参数配置为：8 个时间步 $\times$ 每步 16 个请求 = 128 个请求/策略，Top-K = 10，模拟午餐高峰时段（每步间隔 5 分钟）。仿真流程如下：

1. 为当前策略拟合推荐器；
2. 使用固定种子生成 120 个合成骑手；
3. 对于每个时间步：
 - 更新骑手可用性（减少负载，标记空闲骑手）；
 - 从评估用户中抽样请求用户；
 - 运行推荐器，获取每个用户的 Top-K 推荐；
 - 基于 MNL/Softmax 选择模型模拟用户决策；
 - 根据派单策略分配订单给骑手；
 - 更新骑手状态（位置、负载、收入）。
4. 收集每个策略的最终指标。

2.4.1 MNL 用户选择模型

用户根据效用函数从推荐列表中选择商家，公式如下：

$$U(m) = -0.45 + \alpha_s \cdot \tilde{s}(m) + \alpha_r \cdot r(m) + \alpha_t \cdot \mathbb{I}[m \in \mathcal{T}_u] \quad (5)$$

其中 $\tilde{s}(m)$ 为归一化推荐分数， $r(m) = 1/\log_2(\text{rank}(m) + 1)$ 为排名先验， $\mathbb{I}[m \in \mathcal{T}_u]$ 为真实命中奖励（bonus = 1.75）。不作选择的效用设为 2.0。选择概率由 Softmax 给出。

2.4.2 骑手配送策略

系统实现了四种骑手派单策略，如表 2 所示。

表 2: 骑手派单策略

策略名称	分配方式	核心逻辑
nearest	贪心	选择接驾距离最小的骑手
min_eta	贪心	选择 ETA 最小的骑手
load_aware greedy	贪心	负载感知评分，逐单分配
load_aware batch	批量最优	负载感知 + 容量槽位二分图匹配

2.5 二分图匹配派单算法

对于批量派单模式，在每个时间步将所有待分配订单与骑手容量槽位构成二分图，使用匈牙利算法求最大权匹配。算法流程如下：

步骤一：构建容量槽位。对于每个骑手 r_i ，其当前负载为 l_i ，最大负载为 $L_{\max} = 3$ ，则创建 $c_i = \max(0, L_{\max} - l_i)$ 个容量槽位。每个槽位对应一个虚拟节点，允许同一个骑手接收多笔订单。

步骤二：构建评分矩阵。设订单数为 N_o ，槽位总数为 N_s ，构造评分矩阵 $S \in \mathbb{R}^{N_o \times N_s}$ ，其中：

$$S_{ij} = \text{rider_score}(\text{eta}_{ij}, r_j, \text{accept}_{ij}) - 0.20 \cdot \text{timeout_risk}_{ij} \quad (6)$$

骑手得分的计算为：

$$\text{rider_score} = 0.50 \cdot s_{\text{eta}} + 0.20 \cdot s_{\text{reliability}} + 0.15 \cdot s_{\text{load}} + 0.15 \cdot s_{\text{accept}} \quad (7)$$

其中 $s_{\text{eta}} = 1.0 - \min(\text{eta}/70.0, 1.0)$ ， $s_{\text{reliability}}$ 基于骑手历史准时率， $s_{\text{load}} = 1.0 - \min(l/L_{\max}, 1.0)$ ， s_{accept} 为骑手接单概率估计。超时风险惩罚项定义为 $\text{timeout_risk} = \min(\max((\text{eta} - 45.0)/60.0, 0.0), 1.0)$ 。

步骤三：匈牙利算法求解。调用 `scipy.optimize.linear_sum_assignment` 对负

评分矩阵 $-S$ 求最小代价分配，等价于原始问题的最大权匹配。过滤掉匹配得分极低 ($\leq -10^5$) 的分配结果。

步骤四：执行分配并更新骑手状态。将匹配成功的订单分配给对应骑手，更新骑手位置、负载和收入。每位骑手的收入由基础配送费与距离补偿构成： $income = 5.0 + \eta \times 0.08$ 。

2.6 ETA 估计模型

预计配送时间 (ETA) 由以下分量构成：

$$ETA = t_{wait} + t_{prep} + t_{peak} + \frac{d_{rider \rightarrow store}}{pickup_speed} \times 60 + \frac{d_{store \rightarrow user}}{delivery_speed} \times 60 + t_{load} \quad (8)$$

其中 $t_{prep} = service_minutes + (1 - food_score/5) \times 5$ (商家备餐时间)， t_{peak} 在高峰期加 6 分钟、非高峰期加 2 分钟， $t_{load} = current_load \times 5$ (骑手当前负载惩罚)，配送速度 = 取餐速度 $\times 1.08$ 。

2.7 平台效用函数

综合平台效用函数被定义为各维度指标的加权和，用于从全局视角评估策略的系统级表现：

$$U_{platform} = 0.25 \cdot s_{user} + 0.25 \cdot r_{ontime} + 0.20 \cdot r_{complete} + 0.15 \cdot (1 - g_{merchant}) + 0.10 \cdot (1 - cv_{rider}) - 0.05 \cdot r_{timeout} \quad (9)$$

其中 s_{user} 为用户满意度， r_{ontime} 为准时率， $r_{complete}$ 为订单完成率， $g_{merchant}$ 为商家曝光 Gini 系数， cv_{rider} 为骑手负载变异系数， $r_{timeout}$ 为超时率。该效用函数兼顾了用户体验、配送效率和生态公平三个维度。

2.8 KG 增强与可解释推荐模块

FoodFlow 的轻量 KG 模块(`foodflow/kg.py`)与主推荐器(`foodflow/recommenders.py`)配合工作：前者将现有结构化字段转化为知识图谱三元组和可解释推荐路径，后者在 KG-Tripartite 中把图谱兴趣信号作为三方重排的增强分量。该模块不单独作为外部子项目呈现，而是融入 FoodFlow 的推荐系统主链路。

2.8.1 知识图谱实体与关系设计

知识图谱实体包括：用户实体、商家实体、餐饮类目实体（一/二/三级）、口味实体（由菜品 `taste` 字段抽取）、食材实体、价格区间实体（由订单价格聚合）、评分等级实

体（离散为 low/medium/high/excellent）、区域实体（aor_id）、品牌实体和标准菜品实体。静态三元组以商家为头实体、属性为尾实体，关系包括 has_cat1/2/3、has_brand、located_in_aor、has_price、has_poi_score、has_delivery_score、has_food_score、has_ingredient、has_taste、has_standard_food 等。主项目轻量 KG 共导出约 24 万条静态三元组。

2.8.2 图谱兴趣构造：时间衰减与关系匹配

设用户 u 在时间 t 与商家 i 发生过订单交互，当前推荐请求时间为 T 。历史订单边权采用指数衰减 $w_{u,i,t} = \exp(-\lambda(T-t))$ ，其中 $\lambda = 0.12$ 为衰减系数（以天为单位）。用户对兴趣实体 e 的历史偏好为 $p_{u,e}^{hist} = \sum_{(i,t) \in \mathcal{H}_{u,T}} w_{u,i,t} A_{i,e}$ ，其中 $A_{i,e} = 1$ 表示商家 i 与实体 e 通过静态图谱相连。

下单前点击序列反映当前一餐的短期偏好。设点击序列为 $\mathcal{C}_{u,T} = (c_1, c_2, \dots, c_m)$ ，越靠近下单的点击权重越高： $w_{u,c_j,T}^{click} = \eta \rho^{m-j}$ （ $\eta = 1.6$, $\rho = 0.88$ ）。点击序列生成的临时偏好为 $p_{u,e}^{click} = \sum_{c_j \in \mathcal{C}_{u,T}} w_{u,c_j,T}^{click} A_{c_j,e}$ 。KG-Tripartite 将历史偏好与短期点击偏好合并为轻量图谱兴趣分，并与用户分、商家公平分、ETA 分和供给分共同进入三方重排。

2.8.3 轻量 KG 路径解释

主项目 foodflow/kg.py 将结构化字段转成可解释路径，例如：用户 $\rightarrow$ 历史下单商家 $\rightarrow$ 商家；用户 $\rightarrow$ 偏好品类 $\leftarrow$ 候选商家；用户 $\rightarrow$ 下单区域 $\leftarrow$ 候选商家；用户 $\rightarrow$ 价格段 $\leftarrow$ 候选商家。这些路径来自训练订单、用户品类偏好、商家类目、商家区域和价格段等真实字段。KG-Tripartite 在推荐时会将路径证据、ETA 和曝光补偿一起输出，保证解释引用真实参与推荐/重排的数据。

2.9 路径感知顺路派单

除传统的最近骑手、最小 ETA 和负载感知逐单/批量匹配外，FoodFlow 新增了路径感知顺路派单策略。骑手不再只按直线距离或单点 ETA 评估，而是维护取/送航点序列（route），新单按 cheapest-insertion 算法枚举所有（取餐点，送达点）插入位置，计算边际绕行分钟数：

- **RouteMinETA**：在路径机制下最小化该单 ETA，作为 route 家族的公平基线。
- **RouteBatch (RouteInsertion)**：目标为边际绕行 + ETA（等权），批量版按匈牙利轮次匹配，每轮每骑手至多一单，应用插入后重算下一轮成本。

骑手随时间沿路径行进（每步推进 5 分钟，经过 dropoff 即完成一单），替代“派单即瞬移”的简化假设。新增指标包括平均边际绕行（avg_detour_minutes）和顺路接单率（enroute_pickup_share）。

2.10 真实城市地理编码

TRD 不含坐标，旧实现用高斯随机数合成经纬度。现在通过 `make geocode` 将用户/商家嵌入 LaDe (Cainiao 末端配送数据集) 真实城市的配送 GPS 分布：先粗聚类提取最大密度簇质心 10km 内的城市核心区；每个 `aor_id` 商圈映射到真实高密度簇，商家坐标从簇内真实点采样（约 60m 抖动）；每个 `aoi_id` 居住区取真实锚点，用户在 120m 内散布。元数据写入 `data/processed/geo_note.json`。诚实口径：这不是 TRD 的真实位置，而是“TRD 订单嵌入 LaDe 真实城市空间分布”；但从此距离、ETA 与地图展示具备真实街区尺度。所有行程按直线距离 $\times 1.3$ 道路弯曲系数换算，骑手默认速度校到 25 km/h（电动车市区口径）；备餐与骑手赶往商家并行计时，使 ETA 尺度落在合理区间。

3 系统评估：推荐效果与履约表现

3.1 FoodFlow 系统闭环实验

FoodFlow 主系统在完整 TRD 训练集（1,068,495 条订单）上进行离线推荐评估，并使用 10 个随机种子的动态履约仿真进行系统级评价。以下分别报告推荐侧、履约侧和系统权衡分析。

3.1.1 离线推荐结果

离线评估使用前 300 名测试用户，评估指标包括推荐侧（Recall@K、NDCG@K、MRR@K、HitRate@K）、商家侧（Coverage@20、Exposure Gini、LongTailExposure@20）和校准侧（CategoryJSD@20）。各模型在 $K = 20$ 下的主要指标如表 3 和 4 所示。

表 3: 离线推荐准确性指标（ $K = 20$ ）


模型	Recall@20	NDCG@20
Popular	0.0470	0.0210
BPR-MF	0.1620	0.1068
UserOnly	0.4287	0.3423
KG-Tripartite	0.4263	0.3480
Logistic-LTR	0.4013	0.3412
Seq-Tuned	0.4675	0.3652
Seq-xQuAD-Tripartite	0.4113	0.3426
Session-SPU-Tripartite	0.4119	0.3429

从表 3 和 4 可以得出以下结论：


表 4: 离线推荐多样性与公平性指标 ($K = 20$)

模型	Coverage@20	ExposureGini	CategoryJSD@20
Popular	0.0062	0.9952	0.0581
BPR-MF	0.1350	0.9516	0.0575
UserOnly	0.2841	0.8857	0.0156
KG-Tripartite	0.2927	0.8746	0.0157
Logistic-LTR	0.4290	0.8282	0.4736
Seq-Tuned	0.2884	0.8927	0.0152
Seq-xQuAD-Tripartite	0.2823	0.8904	0.0154
Session-SPU-Tripartite	0.2884	0.8818	0.0158

1. **Seq-Tuned 在离线准确率上最优**: Recall@20 达到 0.4675, NDCG@20 达到 0.3652, 说明外卖推荐场景强烈依赖于复购序列和商家转移信号。
2. **KG-Tripartite 在三方模型中准确率最高**: Recall@20 达到 0.4263, NDCG@20 达到 0.3480, Exposure Gini 低至 0.8746, 说明知识图谱引入的品类/商圈/价位结构化信号在保持品类校准的同时有效提升了排序精度。
3. **Logistic-LTR 在覆盖面上表现最佳**: Coverage@20 达到 0.4290, Exposure Gini 最低 (0.8282), 表明学习排序方法能有效降低曝光集中度。注意当前环境使用 Logistic-LTR 作为学习排序后备方案, 完整 LightGBM-LTR 在 Coverage@20 (0.4345) 和 Exposure Gini (0.7942) 上表现更优。
4. **三方模型离线准确率略低于 Seq-Tuned**: 这是预期的——因为三方模型在排序中纳入了非精确匹配的公平性、配送距离和供给约束, 但需要通过仿真来评估系统级收益。
5. **Popular 和 BPR-MF 表现较差**: Popular 仅靠热度导致 Coverage 极低 (0.0062), Exposure Gini 接近 1; BPR-MF 受限于隐式反馈的稀疏性和维度设置。




(a) 各模型 Recall@20 对比



(b) 各模型 NDCG@20 对比

图 2: 离线推荐准确率指标对比

从图 2 可以直观看出, Seq-Tuned 和 LightGBM-LTR 在 Recall 和 NDCG 上明显领先于其他模型。图 3 则展示了商家侧指标: LightGBM-LTR 的 Coverage 最高、Exposure Gini 最低, 体现了学习排序在突破”热度偏差”方面的优势。



(a) 各模型 Coverage@20 对比

(b) 各模型 Exposure Gini 对比

图 3: 商家侧指标对比

图 4 展示了 CategoryJSD@20 指标——衡量推荐列表品类分布与用户历史品类分布的 Jensen-Shannon 散度。Seq-Tuned 和 UserOnly 在该指标上表现最优，数值越低说明推荐品类越贴近用户真实消费习惯。




图 4: 各模型 CategoryJSD@20 对比

3.1.2 权衡分析：准确率 vs 公平性

推荐系统的核心挑战在于准确率与公平性之间的权衡。图 5a 以 NDCG@20 为纵轴、Exposure Gini 为横轴，展示各模型在准确率-公平性二维空间中的位置。

从图 5 可以看到，Logistic-LTR 位于准确率-公平性前沿的右下角（较高准确率、较低曝光集中度），Seq-Tuned 则位于高准确率但曝光略集中的位置，三方模型在保持较高准确率的同时维持了适中的公平性。

3.1.3 动态履约仿真结果（常规运力 120 骑手）

仿真采用 10 个随机种子重复运行，报告均值与 95% 置信区间。常规运力场景使用 120 名合成骑手、8 个时间步 $\times$ 每步 16 个请求 = 128 个请求/策略，Top-K = 10，MNL/Softmax 用户选择。主要策略链路的完整指标如表 5 所示。

从表 5 可以得出以下结论：




图 5: 准确率与公平性/覆盖面的权衡分析

表 5: 动态履约仿真完整指标（常规运力 120 骑手，10 种子均值 $\pm$ 95% CI）

策略	平均 ETA	超时率	准时率	平台效用
Popular + Nearest	59.06 $\pm$ 2.28	0.579 $\pm$ 0.023	0.421 $\pm$ 0.023	0.391 $\pm$ 0.007
UserOnly + MinETA	41.54 $\pm$ 1.23	0.347 $\pm$ 0.031	0.653 $\pm$ 0.031	0.511 $\pm$ 0.009
Seq-Tuned + MinETA	40.44 $\pm$ 1.21	0.287 $\pm$ 0.041	0.713 $\pm$ 0.041	0.533 $\pm$ 0.012
LightGBM-LTR + MinETA	40.45 $\pm$ 1.11	0.299 $\pm$ 0.028	0.701 $\pm$ 0.028	0.528 $\pm$ 0.011
Seq-xQuAD-Tripartite + Greedy	37.04 $\pm$ 1.91	0.212 $\pm$ 0.046	0.788 $\pm$ 0.046	0.550 $\pm$ 0.012
Seq-xQuAD-Tripartite + Batch	35.90 $\pm$ 1.88	0.195 $\pm$ 0.036	0.805 $\pm$ 0.036	0.553 $\pm$ 0.009
Session-SPU-Tripartite + Greedy	38.14 $\pm$ 1.35	0.220 $\pm$ 0.031	0.780 $\pm$ 0.031	0.557 $\pm$ 0.011
Session-SPU-Tripartite + Batch	36.79 $\pm$ 1.25	0.199 $\pm$ 0.029	0.801 $\pm$ 0.029	0.557 $\pm$ 0.010
KG-Tripartite + Batch	36.90 $\pm$ 1.04	0.211 $\pm$ 0.033	0.789 $\pm$ 0.033	0.550 $\pm$ 0.011
KG-Tripartite + RouteMinETA	36.15 $\pm$ 0.96	0.229 $\pm$ 0.037	0.771 $\pm$ 0.037	0.542 $\pm$ 0.011
KG-Tripartite + RouteBatch	38.84 $\pm$ 1.24	0.311 $\pm$ 0.049	0.689 $\pm$ 0.049	0.517 $\pm$ 0.014

1. 三方方法在履约指标上全面优于纯用户侧方法。Session-SPU-Tripartite + Batch 取得了最高的平台效用 (0.557), Seq-xQuAD-Tripartite + Batch 取得了最低的平均 ETA (35.90 分钟) 和最低的超时率 (0.195)。
2. 批量二分图匹配优于贪心逐单分配。Seq-xQuAD-Tripartite 下, Batch 模式的超时率 (0.195) 低于 Greedy 模式 (0.212), 说明全局最优匹配能有效平衡骑手负载。
3. **KG-Tripartite** 在常规运力下与最优策略统计打平。KG-Tripartite + Batch 的平均 ETA (36.90) 和平台效用 (0.550) 与 Session-SPU-Tripartite 的置信区间重叠, 表明图谱信号与 Session/SPU 信号在推荐-履约链路中具有互补性。
4. 顺路派单在常规运力下 **ETA 与槽位匹配打平**。KG-Tripartite + RouteMinETA 的平均 ETA (36.15) 与 Batch 最优值 (35.90) 的置信区间重叠——骑手大多空闲时, 分散派单即是最优解, 合单不会带来额外收益; 且 route 家族的 ETA 诚实计入队列沿路径行进的时间, 口径更严格。
5. 离线准确率最优不等于仿真效果最优。Seq-Tuned 在离线 Recall 上最高, 但在仿真中超时率 (0.287) 高于三方方法, 说明纯粹追求准确率的推荐可能将订单引导至配送压力大的商家。

3.1.4 运力紧张压力场景 (30 骑手高峰爆单)

为验证顺路派单在高峰爆单场景下的价值, 使用 30 名骑手 (常规运力的 25%) 模拟运力紧张的压力场景。10 种子均值结果如表 6 所示。

表 6: 运力紧张压力场景仿真 (30 骑手, 10 种子均值 $\pm$ 95% CI)

策略	平均 ETA	超时率	平台效用	顺路接单率
Popular + Nearest	76.86 $\pm$ 2.56	0.749 $\pm$ 0.029	0.412 $\pm$ 0.012	—
Seq-Tuned + MinETA	76.64 $\pm$ 2.46	0.819 $\pm$ 0.014	0.442 $\pm$ 0.014	—
Seq-xQuAD-Tripartite + Batch	60.96 $\pm$ 4.84	0.679 $\pm$ 0.046	0.486 $\pm$ 0.017	—
KG-Tripartite + Batch	61.47 $\pm$ 2.85	0.685 $\pm$ 0.039	0.481 $\pm$ 0.014	—
KG-Tripartite + RouteMinETA	44.88 $\pm$ 1.55	0.457 $\pm$ 0.038	0.544 $\pm$ 0.016	0.669 $\pm$ 0.016
KG-Tripartite + RouteBatch	47.34 $\pm$ 1.66	0.515 $\pm$ 0.040	0.525 $\pm$ 0.015	0.666 $\pm$ 0.015

从表 6 可以得出:

1. 顺路派单在运力紧张时大幅反超。KG-Tripartite + RouteMinETA 的平均 ETA (44.88 分钟) 比最优槽位匹配 (Seq-xQuAD-Tripartite + Batch, 60.96 分钟) 低约 16 分钟, 远超置信区间范围; 超时率从 0.679 降至 0.457。
2. 顺路接单率达 **66.9%**。说明在运力吃紧时, cheapest-insertion 路径感知派单能有效利用骑手已有路径顺路接单, 避免远距离单独调度。

3. 无免费午餐。顺路派单不是在所有场景下更优——运力充足时槽位批量匹配的 ETA 更好；顺路合单的优势出现在运力紧张的高峰场景。派单机制可随供需状态切换，这是三方联合视角的核心论据。




图 6: 配送时效指标对比





图 7: 履约质量与平台效用对比

从图 6 和图 7 可以直观看到，三方策略（Seq-xQuAD-Tripartite、Session-SPU-Tripartite、KG-Tripartite）配合 Batch 匹配在平均 ETA、P95 ETA、超时率和平台效用上均显著优于纯用户侧策略。特别值得注意的是，从 Popular + Nearest 到 Seq-xQuAD-Tripartite + Batch，平台效用提升了约 41%（从 0.391 到 0.553），平均 ETA 下降了约 39%（从 59.06 分钟到 35.90 分钟）。


图 8 展示了骑手侧指标。负载感知的派单策略（load_aware）在骑手负载均衡和收入公平性上均优于 nearest 和 min_eta。图 9 显示三方策略在保持较高活跃骑手率的同时，商家曝光 Gini 也更低。

3.1.5 三方帕累托前沿分析

为综合评估推荐准确率与系统效用之间的权衡，图 10a 将各策略映射到 Recall@20（推荐侧）与平台效用（系统侧）的二维空间中，并标注帕累托前沿。




(a) 骑手负载标准差对比




(b) 骑手收入 Gini 对比

图 8: 骑手侧指标对比




(a) 活跃骑手率对比




(b) 仿真中商家曝光 Gini 对比

图 9: 骑手活跃率与商家曝光公平性



(a) Recall@20 与平台效用的帕累托前沿



(b) 平均 ETA 与平台效用的权衡

图 10: 三方权衡与帕累托前沿分析




图 11: 三方策略综合记分卡

从图 10a 可以清晰识别三类前沿策略：

- **离线准确率前沿**: Seq-Tuned 和 Logistic-LTR 代表推荐准确率的上界, 在 Recall@20 上分别达到 0.4675 和 0.4013 (完整 LightGBM-LTR 可达到 0.4424)。
- **系统效用前沿 (常规运力 120 骑手)**: Session-SPU-Tripartite + Batch、Seq-xQuAD-Tripartite + Batch 和 KG-Tripartite + Batch 代表平台效用的上界, 分别达到 0.557、0.553 和 0.550。
- **系统效用前沿 (运力紧张 30 骑手)**: KG-Tripartite + RouteMinETA 在压力场景下平台效用达到 0.544, 远超同场景下最优槽位匹配的 0.486, 说明路径感知顺路派单是高峰爆单时的韧性机制。

这三类策略共同构成了三方推荐的权衡边界——说明在外卖推荐场景中, 纯粹的准确率优化和系统级多目标优化并不完全重合, 需要根据平台的战略偏好进行折中。图 11 的综合记分卡进一步印证了这一发现: 三方模型在配送时效和平台效用上表现优异, 而 Seq-Tuned 在用户侧指标上保持领先。




图 12: FoodFlow Streamlit 交互演示界面——展示推荐工作台、空间分布与高峰回放

4 系统总结与局限

通过本实验，我们构建了完整的”推荐—重排—履约仿真”闭环系统，获得以下主要收获：

1. **推荐系统需要从系统视角评估。** 离线准确率指标（Recall、NDCG）只能反映模型匹配用户历史行为的能力，无法衡量推荐结果对履约链路的下游影响。FoodFlow 通过引入动态履约仿真，揭示了推荐准确率与平台效用之间的权衡关系。
2. **三方重排在履约指标上带来了显著收益。** 在候选排序中纳入商家公平、ETA 和供给约束，虽然会略微牺牲离线准确率，但能显著降低平均 ETA 和超时率，提升平台全局效用。这一发现对实际外卖平台的推荐系统设计具有启示意义。
3. **知识图谱信号能增强三方推荐的排序精度与可解释性。** KG-Tripartite 在三方模型中离线准确率最高（Recall@20=0.4263、NDCG@20=0.3480），同时通过品类/商圈/价位结构化路径提供可解释推荐证据。该能力已经融入 `foodflow/recommenders.py` 的 KG-Tripartite 主链路，而不是作为独立模块单独评估。
4. **二分图批量匹配优于贪心逐单分配。** 匈牙利算法在容量约束下寻求全局最优匹配，相比贪心策略能更均衡地分配骑手负载，降低超时风险。
5. **路径感知顺路派单是高峰爆单时的韧性机制。** 运力充足时，槽位批量匹配的 ETA 更优；但在运力紧张（30 骑手）的压力场景下，cheapest-insertion 顺路派单大幅反超——平均 ETA 比最优槽位匹配低约 16 分钟，顺路接单率达 66.9%。派单机制可随供需状态切换，这是三方联合视角的核心论据。
6. **多种子仿真为策略比较提供了统计置信度。** 10 种子均值和 95% 置信区间的使用使得策略间差异的显著性可以被量化评估，避免了单种子点估计的偶然性。
7. **真实城市地理编码使仿真具备物理意义。** 通过 LaDe 数据集将用户/商家嵌入真实城市配送 GPS 分布，距离与 ETA 具备了真实街区尺度，使仿真结果不再停留于抽象数值。

本实验也存在以下局限性：

- 骑手数据默认来自合成仿真，虽然可使用 LaDe delivery CSV 校准末端配送参数，但仍不能替代工业级外卖派单数据。
- 离线评估默认只使用前 300 名测试用户（全量测试用户约 108,739 名），大规模评估的计算开销较大。
- LightGBM-LTR 当前使用项目构造的候选集和特征，训练标签来自历史下单集合，后续可引入更丰富的上下文特征、真实曝光/点击标签和跨城市验证。

- 仿真中的 MNL 选择模型为简化的用户行为假设，实际用户的下单决策受更多因素影响。
- KG-Tripartite 当前使用的是免训练的轻量图谱近似（时间衰减 + 关系加权匹配），尚未引入端到端图神经网络训练；后续可在现有 `foodflow/recommenders.py` 主链路内继续增强图谱表示学习。
- 当前三方优化采用”推荐重排 + 下单后骑手匹配”的解耦闭环，不是工业级端到端联合调度系统。

总体而言，FoodFlow 验证了”推荐 + 履约联合优化”这一技术路线的可行性。后续工作可以围绕更精细的骑手行为建模（如接单意愿学习、多平台竞争）、KG 表示学习与三方重排的端到端融合、更大规模的真实数据验证以及在线 A/B 测试展开。